

深度学习

IAN GOODFELLOW
YOSHUA BENGIO
AARON COURVILLE

October 19, 2016

Contents

1	介绍	1
1.1	谁应该读这本书	9
1.2	深度学习历史趋势	9
1.2.1	改变神经网络命运的人们	9
1.2.2	不断变大的数据集	15
1.2.3	不断变大的模型	15
1.2.4	不断提高的精确度, 复杂度以及对真实世界的冲击	18
I	应用数学与机器学习基础	23
2	线性代数	27
2.1	标量、向量、矩阵和张量	28
2.2	矩阵和向量乘法	28
2.3	单位矩阵和逆矩阵	28
2.4	线性相关和和线性空间	28
2.5	秩	28
2.6	特殊的矩阵和向量	28
2.7	特征分解	28

2.8 奇异值分解	28
2.9 摩尔-彭若斯广义逆	28
2.10 求迹	28
2.11 行列式	28
2.12 示例: 主成分分析	28
3 概率论和信息论	29
4 数值优化	31
5 机器学习基础	33
5.1 5.7.2	33
II 深度学习: 实战	35
6 深度前馈网络	39
7 深度学习的正则化	41
8 训练深度模型的优化方法	43
9 卷积网络	45
9.1 9.10	45
10 序列模型: 循环网络与递归网络	47
10.1 10.7	47
11 实战方法	49
12 应用	51

12.0.1 12.1.2	51
12.1 12.3	51
III 深度学习研究	53
13 线性模型	55
14 自编码器	57
15 表征学习	59
15.1 15.1	59
16 深度学习的结构化概率模型	61
17 蒙特卡洛方法	63
18 对抗分区函数	65
19 近似推理	67
20 深度生成式模型	69

List of Figures

- 1.1 不同的表达形式的例子：假设我们要在如上散点图中画一条线分割两个不同种类的数据，左图是笛卡尔坐标系中的散点图，这个任务是不可能完成的。右图是该数据在极坐标系中的散点表示，这个任务可以通过画一条垂线就完成了。 3

- 1.2 深度学习模型图解。对计算机而言，理解如像素值等的传感器捕获的原始数据是非常困难的。从一组像素值到物体标签的函数映射是十分复杂的，如果直接来学习或评估这个映射看起来是个不可能的。深度学习通过把这个复杂的映射分解成一系列的简单映射来解决这个问题，每个简单的映射是模型中一个不同的“层” (layer)。原始的数据输入被称为“可视层”，因为它包含着我们要观察的变量。紧接着是一系列的“隐层”不断的从图像中抽取抽象的特征，这些层被称为“隐层”是因为他们的值不是由原始数据直接给出的，模型需要决定哪些概念对解释可观测数据之间的关联是有用的。图示为每个隐层所学习到的概念的可视化。第一个隐层可以十分容易的通过相邻像素之间的明暗对比抽取出边缘的信息，第二层则可以通过轮廓信息学习出角点和轮廓的信息，第三层则可以通过角点和轮廓的信息寻找到指定物体的一些部件信息。最终，通过对物体的部件描述，我们可以识别出图像中的物体。 5

- 1.3 每一个节点表示一个不同的操作，图示为从输入到输出映射的计算图。深度是从输入到输出的最长路径，但它的计算依赖于对独立计算步骤的定义。上图描述的是逻辑回归的模型 $\delta(w^T x)$ ， δ 是逻辑回归的 sigmoid 函数。如果我们认为加法、乘法和 sigmoid 操作是计算机语言的元素级操作，那这个模型的深度就是 3；如果我们认为逻辑回归本身就是元素级操作，那这个模型的深度就是 1。 6

- 1.4 这个维恩图解释了为什么深度学习也是一种表征学习的方法和机器学习方法。维恩图的每个部分都给出了一个 AI 方法的实例。 7

- 1.5 此图显示了不同的 AI 算法是如何组成 AI 系统的不同部分的。深色的框表示这个模块是可以从数据中学习的。 8
- 1.6 本书的组织图。如果箭头从第 A 章指向第 B 章，意味着理解章节 B 的需要 A 的知识。 10
- 1.7 本图展示了人工神经网络研究的发展史上三次浪潮中的两次，根据 Google Books 中提到控制论、联结学或神经网络的批量得出的测量（第三次浪潮是最近才出现的）。第一次浪潮是在 1940-1960 间出现的控制论，伴随着生物学习理论的发展和第一个允许训练的单个神经元的感知元模型的建立。第二次浪潮是 1980-1995 年出现的联结学，那时出现了反向传播算法，我们可以训练拥有一到两个隐层的神经网络了。现在是第三次浪潮，从 2006 年开始的深度学习，直到 2016 年才被写进书中。不过另外两次浪潮也一样，也是滞后于相关科技的发展很长时间才被书中收录。 11
- 1.8 数据集随着时间剧增。在二十世纪初期，统计学家使用成百上千次的手工编译研究数据集。在二十世纪五十年代到八十年代期间，受生物学启发的机器学习先驱经常使用的是小的、合成的数据集，比如信件的低分辨率位图，这些数据的使用是为了减少计算量的基础上使用神经网络实现特定功能。在二十世纪八十年代到九十年代，机器学习变得更加偏统计，并且开始使用万量级的数据集，比如 MNIST（如 1.9）就是手写数字的扫描。在二十一世纪的前十年，出现了更多更复杂的数据集也是在这个量级，比如 CIFAR-10 就在持续的增加。在二十一世纪一零年代的前半部分，从十万到千万量级的更大的数据集完全的改变了深度学习能力的界限。这些数据集包括 Street View House Numbers，不同版本的 ImageNet，Sports-1M 等。在图的顶端我们可以看到翻译句子的数据集，比如由 Canadian Hansard 构造的 IBM 数据集，还有 WMT2014 英法翻译数据集等都远超过了其他数据集的量级。 16
- 1.9 MNIST 数据集的示例。“NIST”意思是国家标准技术研究所，就是一开始收集这些数据的机构。“M”意思是“改变的”，因为这批数据为了使得机器学习算法更简单的应用进行了预处理。MNIST 数据集集中有 0-9 的手写数字的扫描数据以及相应的标签。这个简单的分类是深度学习研究中最简单也最为广泛使用的测试。尽管这个任务对现代的技术来说很简单，但仍然很流行。Geoffrey Hinton 称其为“机器学习的果蝇”，意味着机器学习研究者可以在可控的实验条件下研究他们的算法，正如生物学家经常使用果蝇来帮助研究一样。 17
- 1.10 foo bar 19

1.11 foo bar	20
1.12 自从深度网络达到了可以参与 ImageNet 竞赛的规模，就连续获得了多年的冠军，且每一年的错误率都有降低。	22

List of Tables

1

介绍

1

发明家们一直梦想着做出能思考的机器。这种愿望可以追溯回古希腊时期。皮格马利翁¹，代达罗斯²，赫菲斯托斯³等神话形象可以被认为是传奇的发明家；而嘉拉迪雅⁴，塔洛斯⁵，潘多拉⁶则可以被认为是人造生命。

当人们第一次设想制造可编程计算机时，就在想能否使它们变得智能，而可编程计算机在 100 多年之后才问世⁷。今天，人工智能（AI）是一个有许多实际应用和活跃研究课题的热门领域。而且我们希望智能软件可以自动完成日常劳动，理解语音和图像，进行医学诊断和支持基础科学研究。

在人工智能发展的早期，AI 迅速的解决了那些对人类来说困难但对计算机而言相对简单的问题，这些问题可以明确的被一系列的公式和数学规则所定义。而人工智能面临的真正挑战后来变成了解决对人类来说执行起来容易但定义规则困难的问题。这些问题就像理解语言，或识别人脸，对人类而言感觉像自动的，仅凭直觉就能处理的。

本书探讨的是解决上述问题的方法。这类方法允许计算机通过建立层级概念从经验中学习和理解世界，而每个概念由一系列与其相关且更简单的概念组成。通过从经验中获取知识，这类方法避免了人工的指定计算机所需要的知识。概念的层级性使得计算机可以通过简单的概念学习更为复杂的概念。如果我们画出概念是如何组织和建立的，这幅画会有很多层级，会很

¹善雕刻的国王

²希腊名建筑师

³火神

⁴皮格马利翁的雕刻作品，化身为人类

⁵代达罗斯外甥，向他学艺成为大师

⁶赫菲斯托斯用泥土造的女人

⁷Lovelace, 1842, 被视为第一位给计算机写程序的人

深。因此，我们将这类方法称为深度学习。

许多早期的成功的 AI 大多是应用在相对简单和有规律的环境中，并不要求计算机对环境有过多认知。例如，IBM 的深蓝系统在 1997 年打败过国际象棋的世界冠军 Garry Kasparov。国际象棋是一个非常简单的世界，因为他的 32 个棋子必须在 64 个棋格中严格按照规律移动。找到一个成功的下棋策略当然是一个非常大的成功，但其挑战并不在于描述下棋的位置和移动的方向。国际象棋可以被一系列简单有条理的规则提前被程序员定义。

有些嘲讽的是，那些对于人类很难解决的规则化和抽象的任务对于计算机来说恰恰是比较容易的。计算机很久之前就已经打败了国际象棋的人类冠军，但仅仅到近年才能在识别图像和语音上能稍微和人类的平均水平匹敌。人的日常生活需要对真实世界的大量认知。许多知识对我们而言是主观的和本能的，因此很难通过正式的方式明确的表达出来，而计算机需要这类知识来使其表现的更加智能。AI 的关键挑战之一就是如何使计算机学习到这些非结构化的认知。

一些 AI 的项目曾经试图将知识以硬编码的方式写入专门的语言中，计算机使用逻辑和规则推理这些语言中的语句，这种方法被称为“知识库”。然而，这些项目都没有获得巨大的成功。其中最著名的是 Cyc，Cys 是一个推理引擎，CycL 是其专有的知识语言库，人通过繁重的工作将知识语言录入 CycL 中。他们企图通过足够复杂的规则来精确的描述这个世界，但结果不尽如人意。比如，Cyc 不能正确的理解 Fred 在早上刮胡子这个故事。推理引擎捕捉到了故事中的矛盾：它知道人类并没有电动的组成部分；但由于 Fred 拿着电动剃须刀，使得推理引擎认为 Fred 是一个包含电动部分的实体。因此，推理引擎不知道此时 Fred 是否还是人类。

上述的硬编码的知识系统的失败表明，AI 需要从原始的数据中提取模式并学习知识，这种能力被称为“机器学习”。机器学习的引入使得计算机能够处理真实世界的问题并作出主观性的决策。一种叫做“logistic 回顾”的简单机器学习算法可以决定是否推荐剖腹产，一种“叫做朴素贝叶斯”的简单机器学习算法可以做垃圾邮件的分类。

上述的简单机器学习算法非常的依赖输入数据的表现形式。比如，当 logistic 回归被用于是否推荐剖腹产的时候，这个算法并不直接检查孕妇，而是通过医生输入的血压、病史等相关参数来做决策。每个参数被称为一个特征。logistic 回归知道每个特征和最后输出的关联，然而，他不能影响特征被定义的方式。如果给出一个孕妇的核磁共振结果而非是医生的结构化的参数报告，logistic 回归就不能得出有意义的结果了。核磁共振扫描结果上的每个独立像素和生产中的可能发生的并发症的相关性十分微小。

对特征表达形式的依赖是计算机科学甚至日常生活中的一个普遍现象。在计算机科学中，如果数据按照某种格式组织索引，搜索工作会获得指数倍的效率提升。人们能够很容易的对阿拉伯数字做运算，而对罗马数字的运算会耗费更多时间。所以特征的表达对于机器学习算法可能产生的巨大影响也

不足为奇了。图1.1展示了一个直观的例子。

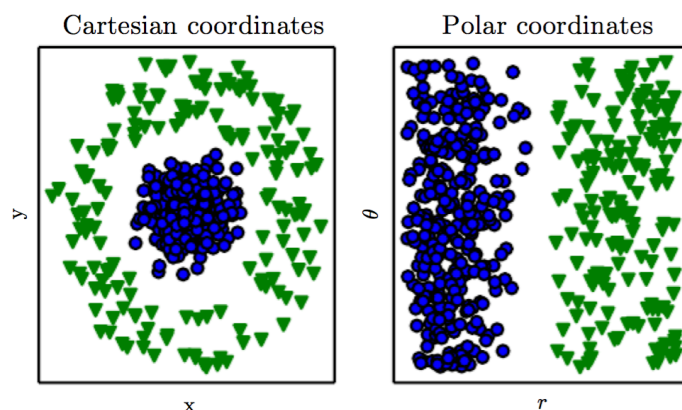


Figure 1.1: 不同的表达形式的例子：假设我们要在如上散点图中画一条线分割两个不同种类的数据，左图是笛卡尔坐标系中的散点图，这个任务是不可能完成的。右图是该数据在极坐标系中的散点表示，这个任务可以通过画一条垂线就完成了。

许多人工智能的任务可以通过手工设计合适的特征组并输入一个简单的机器学习模型来完成。比如，说话人的声道大小是说话人识别任务的一个有用的特征，他可以作为说话人是男人、女人或是小孩的一个强线索。

然而，对许多任务来说，我们很难去发现应该抽取什么样子的特征。比如，我们需要在一张照片中检测车辆。我们知道汽车有轮子，所以我们可能会把轮子作为汽车检测的一个特征。不幸的是，在像素的级别上描述轮子是非常困难的。轮子的几何形状非常简单，但是轮子上的阴影、金属部分的折射、保险杠的影响或前景物体的遮挡等让描述它变得非常复杂。

上述问题的一个解决方案是，我们不仅使用机器学习的算法去学习特征表达到输出结果之间的映射，也使用机器学习去学习起特征表达，这种方案被称为“表征学习”。表征学习通常可以获得比手工特征更好的表现，它也让AI系统在很少的人工干预下可以快速的适应新的任务。表征学习算法可以为一个简单的任务在数分钟之内找到一组好的特征，复杂的任务耗时则从几小时到几个月不等。为一个复杂的任务人工的设计特征需要耗费大量的时间和精力，甚至可能花费整个研究团队数十年的时间。

表征学习的一个经典算法叫做“自编码器”。自编码器有两部分组成：编码器把输入的数据转换到不同的表征空间；解码器把这个表征再转换回原始的数据。自编码器的训练目标一个是在不断的编码和解码的过程中保存尽量多的信息，另一个是在表征空间中有良好的属性。不同的任务需要自编码器有不同的属性。

不管是手工特征还是学习的特征，我们的目标通常是分离出观测数据的“变化因子”。在本文中，我们使用“因子”来表示不同的影响源，这些因子通常都不是通过乘法来组合的，这些因子也通常不能通过直接观测来量化。相反的，这些因子或许存在在物理世界中尚未发现的物体或力量中但对可观测的量造成了影响。这些因子也可能存在于人类大脑的结构中，提供对可观测数据的推理和抽象解释能力。当分析一段录音时，变化因子包括说话人的年龄、性别、口音和他所说的一字一句。当分析一幅汽车的图像时，变化因子包括车的位置、颜色、阳光的角度和亮度。

许多真实世界的 AI 应用面对的主要问题来源就是许多的变化因子影响着观测到的每一份数据。图像上一辆红色的车的像素值在夜晚的时候会非常靠近黑色。汽车的轮廓表现在不同的观测角度下是不同的。绝大多数的应用都需要我们对变化因子解耦并且丢弃那些我们不关心的变化因子。

从原始数据中抽取如上所说的高层次和抽象的特征固然是非常难的。如说话人口音在内的许多变化因子，都需要对数据具有非常精致和复杂、接近人类的理解能力才能获取。当获取一个合适的特征表达的难度几乎和解决原始问题相当的时候，表征学习似乎并不能给我们带来帮助。

“深度学习”通过表征的层级组合解决了表征学习中的核心问题。深度学习允许计算机通过学习一系列简单的概念来组成复杂的概念。图1.2 展示了深度学习如何从图像中通过一些如边缘，角点，轮廓的简单的特征组合来表示一个人的。

前馈神经网络或多层感知机 (MLP) 是深度学习的一个典型例子。多层感知机不过是把输入映射到输出的数学函数，而这个函数是由许多更简单的函数组成的，且我们可以认为应用不同的数学函数可以提供对输入数据的不同表征。

学习合适的表征是深度学习的一方面，另一方面是“深度”允许计算机学习到分步的计算过程。每一层的表征都可以被认为是计算机并行的执行了一系列的指令集后的记忆状态，更深层次的网络可以按照序列顺序执行更多的指令集。序列的指令拥有更强大的能力，因为它可以从前序的指令的结果中获得参考。根据深度学习的这些观点，并不是层中激活的所有信息都可以编码对解释输入数据的起作用的变化因子。表征会存储有利于算法执行、使得输入有意义的状态信息。在传统计算机程序中，状态信息可以类比于计数器或者指针，它与输入内容没有直接的关系，但是可以帮助深度学习模型组织其自身的处理过程。

有两种主要的方法可以测量一个模型的深度。第一种是统计在测试网络的过程中必须被执行的序列指令的数量，可以认为这是描述模型从输入到输出的流程图中的最长路径。就像相同的程序由于编程语言的不同会有不同的长度，对于同一个函数，其在流程图中的长度取决于我们把哪些步骤看作是独立的。图1.3描述了不同的语言是如何使得同一个结构拥有不同的深度。

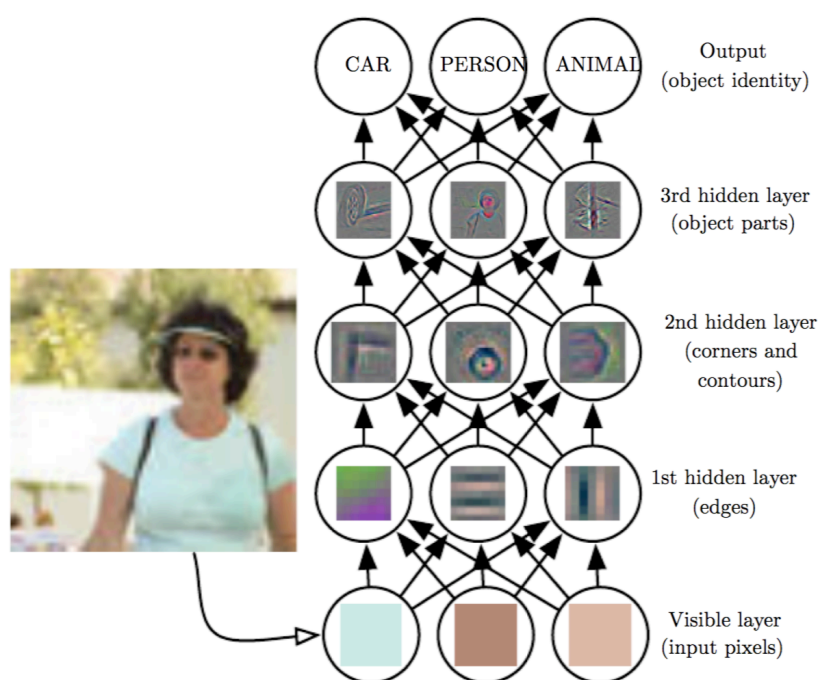


Figure 1.2: 深度学习模型图解。对计算机而言，理解如像素值等的传感器捕获的原始数据是非常困难的。从一组像素值到物体标签的函数映射是十分复杂的，如果直接来学习或评估这个映射看起来是个不可能的。深度学习通过把这个复杂的映射分解成一系列的简单映射来解决这个问题，每个简单的映射是模型中一个不同的“层”（layer）。原始的数据输入被称为“可视层”，因为它包含着我们要观察到的变量。紧接着是一系列的“隐层”不断的从图像中抽取抽象的特征，这些层被称为“隐层”是因为他们的值不是由原始数据直接给出的，模型需要决定哪些概念对解释可观测数据之间的关联是有用的。图示为每个隐层所学习到的概念的可视化。第一个隐层可以十分容易的通过相邻像素之间的明暗对比抽取出边缘的信息，第二层则可以通过轮廓信息学习出角点和轮廓的信息，第三层则可以通过角点和轮廓的信息寻找到指定物体的一些部件信息。最终，通过对物体的部件描述，我们可以识别出图像中的物体。

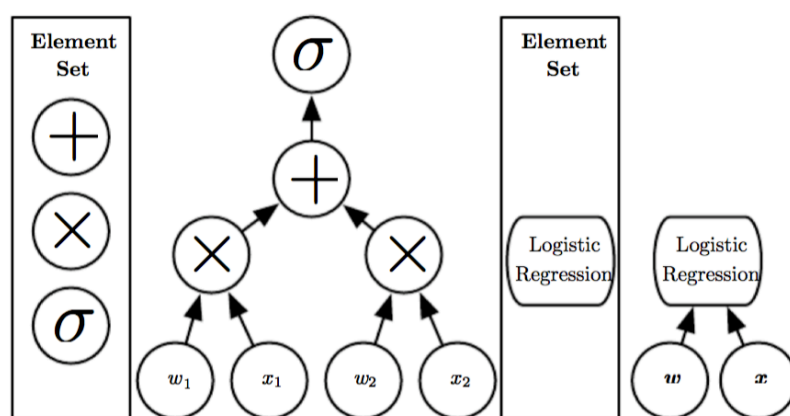


Figure 1.3: 每一个节点表示一个不同的操作，图示为从输入到输出映射的计算图。深度是从输入到输出的最长路径，但它的计算依赖于对独立计算步骤的定义。上图描述的是逻辑回归的模型 $\delta(w^T x)$ ， δ 是逻辑回归的 sigmoid 函数。如果我们认为加法、乘法和 sigmoid 操作是计算机语言的元素级操作，那这个模型的深度就是 3；如果我们认为逻辑回归本身就是元素级操作，那这个模型的深度就是 1。

另一个由深度概率模型所使用的概念是，深度并不是计算流程图的深度，而是描述概念之间的层级结构的组织图的深度。在这个概念中，由计算流程图得到的深度往往比概念组织图得到的深度要深得多。比如，一个 AI 系统如果在观测一副有一只眼睛在阴影中的人脸图像时可能刚开始只能观测到一只眼睛，等到能发现整个人脸的时候，AI 可能会推理出另一只眼睛也是存在的。在这个例子中，概念组织图只有两层：一层是检测眼睛，一层是认知人脸；但如果我们 n 次调优每一层概念时，计算流程图中则有 $2n$ 层。

该选择计算流程图还是概念组织图来计算深度是没有定论，而且每个人选择构建图所使用的最小元素也不尽相同，因此对一个架构来说并没有一个唯一的正确深度，就像对计算机程序来说也没有一个唯一的正确深度。同样，对于一个模型来说，多深才叫“深”也没有定论。可以肯定的是，相比传统的机器学习来说，深度学习可被认为是一种含有大量计算的函数学习和概念学习的模型。

总之，本书的主题“深度学习”是 AI 的一种实现方法，而且它也是一种可以使得机器自身通过数据和经验不断提升的机器学习方法。本书的作者们认为，深度学习是构建在真实世界处理复杂问题的 AI 系统的目前唯一可行的方法。深度学习是机器学习中很强大很灵活的一种方法，因为它学习的是如何将真实环境中的任务以嵌套的层级概念表达出来，通过这些嵌套的概念，它可以将底层的表征不断抽象为含有语义的更高层的特征。图1.4显示了不同的 AI 方法之间的关联，图1.5概括了这些方法是如何实现的。




Figure 1.4: 这个维恩图解释了为什么深度学习也是一种表征学习的方法和机器学习方法。维恩图的每个部分都给出了一个 AI 方法的实例。




Figure 1.5: 此图显示了不同的 AI 算法是如何组成 AI 系统的不同部分的。深色的框表示这个模块是可以从数据中学习的。

1.1 谁应该读这本书

这本书对很多类型的读者都有用处，但我们主要为两类读者而写。一类是正在学习机器学习的本科生或研究生，或准备开始在深度学习和人工智能的研究领域大展身手的人。另一种是想要快速把深度学习技术应用在他们的产品中，但没有机器学习或统计背景的工程师。深度学习已经在多个软件领域中获得了成功，包括计算机视觉、语音识别、自然语言处理、机器人、生物信息学和化学、视频游戏、搜索引擎、在线广告及金融等。

为适应尽可能多的读者，本书主要由三部分构成。第I部分介绍基础的数学工具和机器学习的概念。第II部分介绍了最为广泛使用的深度学习算法。第III部分介绍了被认为对深度学习的进一步研究十分重要的更远的想法。

读者可以根据自身的背景或感兴趣的方向自由的阅读本书。对线性代数、概率和基础机器学习算法熟悉的读者可以跳过第I部分，而只想实现一个可用的深度学习系统的读第II部分就够了。图1.6提供了本书的一个高层的组织流程图。

我们写本书的时候假设本书的读者都具有计算机科学的相关背景，因此我们也认为大家都熟悉编程、对计算性能和算法复杂度有基本认识、有入门级的微积分和图论的知识。

1.2 深度学习历史趋势

伴随着历史的轨迹来看深度学习是最容易让人理解的一种方式。我们找出了一些深度学习发展的关键趋势而非提供一个详尽的发展历史：

- 深度学习有着悠长和丰富的历史，也有许多人抱持着不同的哲学观点，但它的发展并非一帆风顺。
- 当可以获取的训练数据逐步增长时，深度学习的成效也在增长。
- 当适用于深度学习的软硬件提升时，深度学习模型的大小也在增长。
- 深度学习解决复杂问题能力和精确度随着时间不断提升。

1.2.1 改变神经网络命运的人们

我们期待着本书的读者听说过深度学习这个令人兴奋的新技术，能非常惊喜的看到有一本书在介绍这个新兴领域的历史。事实上，深度学习在 1940 年左右就已经出现。深度学习显得很新是过了很多年前它并不十分流行，而且




Figure 1.6: 本书的组织图。如果箭头从第 A 章指向第 B 章，意味着理解章节 B 的需要 A 的知识。

它有许多不同的名字，直到最近才被称为深度学习。深度学习被多次更名，这也可以反映出不同的研究人员和不同的角度观点带来的影响。

本书并不意在介绍深度学习的全面历史，但是一些基础的认知可以帮助我们理解深度学习。广泛的说，深度学习的发展有三次浪潮：深度学习在 1940-1960 年间被认为是“控制论”，在 1980-1990 年间被称为“联结学”，从 2006 年后才被称为深度学习。这在图1.7中量化的表示了。

一些早期的学习算法在今天我们认识到其实是生物学习的计算机模型，即模仿大脑学习的机制。因此，深度学习的一个别名就是人工神经网络 (ANNs)，与之一致的观点是深度学习模型是受生物大脑启发的一个工程系统（人类大脑或其他动物的大脑）。这种机器学习中使用的神经网络有时候也会被用来理解大脑运行的机制，但这些网络一般没有被设计成实现生物机理的真实模型。从神经角度看深度学习的观点主要有两个思想。一个是大脑证明了智能的行为是可能的，一个直观的想法就是发现大脑运行背后的计算规则并复制其能力。另一种观点是，理解大脑和人智力背后隐含的原理是非常令人感兴趣的，所以揭示了这些基础科学问题的机器学习模型除了解决工程应用的问题外也是非常有意义的。

现代所说的深度学习已经超越了神经角度描述的任何种类的机器学习模型，它成为了一种更为普世的学习多层结构的指导原则，可以被应用于非神经学启发的机器学习模型构建。




Figure 1.7: 本图展示了人工神经网络研究的发展史上三次浪潮中的两次，根据 Google Books 中提到控制论、联结学或神经网络的批量得出的测量（第三次浪潮是最近才出现的）。第一次浪潮是在 1940-1960 年间出现的控制论，伴随着生物学习理论的发展和第一个允许训练的单个神经元的感知元模型的建立。第二次浪潮是 1980-1995 年出现的联结学，那时出现了反向传播算法，我们可以训练拥有一到两个隐层的神经网络了。现在是第三次浪潮，从 2006 年开始的深度学习，直到 2016 年才被写进书中。不过另外两次浪潮也一样，也是滞后于相关科技的发展很长时间才被书中收录。

现代深度学习的先驱是受神经学启发的简单线性模型。这类模型有 n 个输入 x_1, \dots, x_n 和一个输出 y ，目标是学习一组权重 w_1, \dots, w_n 使得

$f(\mathbf{x}, \mathbf{w}) = x_1 w_1 + \dots + x_n w_n$ 。第一次神经网络研究的热潮如图1.7所示，被称为控制学。

McCulloch-Pitts 神经元是一个描述大脑功能的早期模型，这个线性模型可以通过 $f(\mathbf{x}, \mathbf{w})$ 输出的正负来做二分类，当然，权值需要根据分类任务的不同进行相应的调整，而这些权值是需要人工设置的。直到 1950 年代，感知机出现了，它是第一个可以根据不同类别的数据对权值进行自动调整的模型。与此同时出现的自适应线性元件 (ADALINE)，通过简单地返回函数 $f(\mathbf{x})$ 来预测一个实数，也具有从数据中学习预测数字的能力。

这些简单的学习算法极大的影响了现代机器学习算法的版图。用于训练 ADALINE 的算法叫做随机梯度下降，经过稍微修改的随机梯度下降算法是目前绝对主流的深度学习训练算法。

感知机和 ADALINE 使用的 $f(\mathbf{x}, \mathbf{w})$ 类型的模型被称为线性模型。这类模型至今仍然被广泛的使用着，但如今的训练方法很多时候和最初的训练方法不同。

线性模型有许多局限性。最著名的一个是他不能学习异或函数，即 $f([0, 1], \mathbf{w}) = 1$ 且 $f([1, 0], \mathbf{w}) = 1$ ，但 $f([0, 0], \mathbf{w}) = 0$ 且 $f([1, 1], \mathbf{w}) = 0$ 。发现了线性模型这一缺陷的批评家引起了普遍性对生物启发学习的反弹，引起了第一次神经网络热度的退潮。

现在，神经科学仍然被认为是深度学习的一个重要灵感来源，但它已经不再被认为是这个领域的绝对指南。

今天，神经科学对深度学习研究的影响逐渐减弱，因为我们没有足够关于大脑运作机制的信息可以给出指导。如果要深刻理解大脑使用的算法，那就必须同时观测成千上万互相连接的神经元的活动，然而我们做不到这些。因此，我们和理解最简单和被研究的最透彻的大脑部分都相距甚远。

神经科学使得我们希望用一个深度学习的模型来解决不同的问题。神经学家发现雪貂可以利用大脑的声音处理区域学会“看”，如果这个区域被输入视觉信号的话。这证明了多数哺乳动物也许是使用某种单一的算法来使得大脑解决不同的问题。在这个假设出来之前，机器学习的领域是碎片化的，来自不同社区的研究人员在研究不同的领域，如自然语言处理、计算机视觉、运动规划和语音识别等。如今，这些社区仍然是独立的，但深度学习的研究团队可能会同时研究上面所说的许多领域。

我们可以从神经科学中得到一些粗略的指导。如通过不同计算单元的联结来使得系统变得智能就是受到大脑的启发。Neocognitron 创造的一种处理图像的强大模型框架的灵感就来自于哺乳动物的视觉系统，随后这个模型成为了现代卷积网络的基础框架，这个模型在第章会再详细介绍。目前所使用的神经网络绝大多数建立在一个叫做线性整流单元的模型基础上，Cognitron 提供了一个更复杂的模型，这个模型也是受到大脑运作机制的启

发而来。现代这个简化版本是由许多的观点整合而来的，如 Nair、Hinton、Glorot 就援引了神经科学的观点，Jarrett 就更多的从工程角度进行了援引。神经科学虽然是一个重要的灵感源泉，但它不需要被视为刚性的指导。我们知道真实的神经元与线性整流单元的运算机制不尽相同，但更为写实的神经元工作机制并没有给机器学习带来很大的提升。虽然神经科学成功的激发了一些神经网络结构的建立，但我们现在对神经元的学习机制的掌握还不够，还不足以为训练这些结构的学习算法带来足够的指引。

媒体经常强调深度学习和大脑有多么相似。虽然深度学习的研究者和其他机器学习领域的研究者相比更容易引用脑科学的文章，但我们不应该把深度学习看做对大脑的一种模拟。现代深度学习从许多领域汲取养分，特别是一些应用数学的领域，如线性代数、概率论、信息论以及数值优化等。当一些深度学习研究人员援引神经科学作为一种重要灵感源泉时，另一些研究人员或许压根不关心神经科学。

理解大脑在算法级别的运作的工作是值得关注的。这类工作被称为是“计算神经科学”，是不同于深度学习的一个研究领域，许多研究者会在这两个领域之间游走。深度学习的领域主要关心的是如何建立具有可解决问题的智能系统，而计算神经科学的领域的重点工作是建立大脑运作的更精确的模型。

在 1980 年代，迎来了神经网络研究的第二次热潮，这次热潮主要是通过联结学或并行分布式处理的运动产生。联结学在认知科学中产生，认知科学是一种为了理解大脑的跨学科研究，并且有许多不同的层面的分析。在 1980 年代早期，许多认知科学家都在研究符号推理，尽管符号推理很流行，但是符号模型是如何用神经元在大脑中实现的都难以解释。联结学家就开始研究那些可以被神经元实现的认知模型，复兴了心理学家 Donald Hebb 在 1940 年代提出的许多想法。

联结学的核心思想就是通过联结许多简单的计算单元可以实现智能。这个洞见也适用于生物神经系统的神经元和计算模型的一些隐藏单元。

1980 年代联结学运动中产生了一些核心观念对今天的深度学习来说仍然至关重要。

其中一条概念就是分布式表达。这个概念描述的是每个对系统的输入都应该由许多的特征来表达，而每个特征都应该参与到许多的输入的表达。比如，我们有一个可以识别汽车、卡车、鸟的视觉系统，我们识别的物体可能是红的、绿的或者蓝色的。一种表达这些输入的方式是，我们有许多独立的神经元组或隐藏神经元组来处理九种不同的排列组合：红卡车、红汽车、红鸟、绿卡车、绿汽车等。这需要九个不同的神经元组，而且每一组都需要独立的学习相关的物体和颜色的概念。一个提升效能的方法就是使用分布是表达，使用三组神经元描述颜色，三组神经元描述物体信息，这样就只需要六组神经元而非九组。学习红色的神经元可以从汽车、卡车和鸟的图像中学习，而不限于特定的类型。分布式表达对本书非常重要，会在第15章进行更详细的描述。

另一个联结学运动的主要成就是成功的运用了反向传播来训练深度神经网络，并使得反向传播算法流行起来。这个算法在历史的流行度上有过跌宕起伏，但在目前深度学习的领域占了绝对的主导地位。

在 1990 年代，研究者们在使用神经网络进行序列模拟方面取得了很大的进步。Hochreiter 和 Bengio 解决了建模长序列的几个关键数学难题，在第10.1中会提到。Hochreiter 和 Schmidhuber 提出了长短期记忆网络 (LSTM 网络) 来解决序列建模中遇到的一些难题。如今，LSTM 广泛的应用在很多序列建模的任务中，比如 Google 就使用它来做一些自然语言处理的工作。

神经网络的第二次浪潮一直持续到二十世纪九十年代中期。风险投资公司在寻求基于神经网络的和其他 AI 技术的投资机会时，往往会提出十分具有野心但不切合实际的要求。当 AI 的研究不能满足这些不合理的期望时，投资者会感到失望。而与此同时，机器学习的其他领域取得了进步。核方法和图模型在许多重要任务上都获得了良好的表现。这两个因素导致了神经网络浪潮的一次衰退，这次衰退延续到了 2007 年。

在这次退热中，神经网络还持续的在一些任务上取得进展。加拿大先进技术研究院 (CIFAR) 通过倡议进行神经计算和自适应感知 (NCAP) 的研究保持了神经网络研究的存续。这个项目团结了以多伦多大学的 Geoffrey Hinton、蒙特利尔大学的 Yoshua Bengio 和纽约大学 Yann LeCun 为首的机器学习研究团队。CIFAR NCAP 研究计划具有多学科的自然属性，有神经科学家、人类专家以及计算机视觉的专家参与其中。

在那个时候，深度网络被普遍的认为是难以被训练的。我们现在知道了二十世纪八十年代就存在的算法就可以工作的非常好，但在 2006 年前我们还没清楚的认识这一点，这个原因可能是那些算法的计算量对当时的硬件来说太大了，难以进行很多次实验。

神经网络的第三次热潮由 2006 年的一次突破开启。Geoffrey Hinton 展示了一种叫做深度信念网络的神经网络结构，这个网络可以用贪婪的逐层预训练策略来达到高效的训练，这个网络在15.1中会展开详细的介绍。CIFAR 附属的其他研究团队很快的就发现了这个策略也可以适用于训练其他的深度网络，并可以系统的提高在测试样本中的泛化能力。这次热浪推动了深度学习的普及，研究者们现在能训练以前难以想象的更深的神经网络，并且开始重点关注深度的理论意义。现在，深度神经网络已经超越了其他机器学习技术的 AI 系统，也超过了使用手工特征的智能系统。第三次浪潮在本书撰写的时候仍然在持续，虽然在这次浪潮中深度学习研究的重点发生了极大的变化。第三次浪潮始于对新的无监督学习技术和在小数据集上获得良好泛化能力的深度模型的关注，但现在的人们对于更老的有监督学习算法以及处理大量标注数据集的深度模型的能力更感兴趣。

1.2.2 不断变大的数据集

可能很多人会疑惑，第一次对人工神经网络的实验是在二十世纪五十年代，但为什么深度学习直到最近才被认为是一项关键技术。在二十世纪九十年代的时候，深度学习就在商业应用中取得了成功，但那时深度学习更被认为是一项只有专家能够使用的艺术而非技术，不过深度学习算法确实是需要一些技巧才能获得良好的表现。幸运的是，随着训练数据的不断增大，所需要的技巧也不断减少。今天在复杂任务上获得与人类水平相当的学习算法和二十世纪八十年代难以解决的玩具问题⁸所使用的学习算法基本是相似的，但训练模型的算法简化了，可以训练非常深的结构。最重要的进步是如今我们可以给算法提供所需要的资源，帮助算法取得成功。图1.8展示了数据集的大小是如何与日俱增的。这种趋势是被整个社会的数字化所驱动，当计算机领域的活动越来越多，越来越多的行为也被记录。随着电脑互联的程度增加，集中这些记录变得更加容易，也更加容易的把这些数据变为适用于机器学习应用的数据集。“大数据”时代使得机器学习更加容易，因为统计估计这个关键负担被认为是减轻了不少，因为模型对少量数据观测后在新的数据上也能获得不错的泛化能力。到 2016 年，一个粗略的规则是 5000 个标注的数据可以获得可接受的表现，到标注数据达到千万级别时模型的能力能与人类相比或超越人。当训练数据少于此的时候如何让模型仍然获得成功是一个重要研究领域，特别侧重于如何用无监督或者半监督的算法使用大量的未标注数据。

1.2.3 不断变大的模型

另一个神经网络现在获得广泛成功的原因是如今我们有计算资源可以计算更大的模型。联结学的主要认知之一就是当有许多神经元联结在一起的时候动物才能变得智能。一个独立的神经元或者一小组神经元并不是特别有用。

生物的神经元并不总是密集的联结的。如图1.10，我们的机器学习模型中每个神经元都有一定的连接数，这个数量随着时间变化已经逼近了哺乳动物大脑的连接数的量级。

就神经元的总数而言，神经网络在今天之前的量级小的令人惊讶，图1.11表明了这点。自从引进了隐藏单元，人工神经网络的大小每 2.4 年会翻一倍，这个增长是由于不断有更大内存计算速度更快的计算机出现，也是由于数据集的不断增大。更大的网络可以在更复杂的任务上获得更高的精度。这个趋势目前来看还可以持续数十年。除非有新的技术出现，不然人工神经网络至少要到 2050 年左右才能有人类大脑数量的神经元。生物的神经元与目前的人工神经元相比可以表达更复杂的函数，因此生物神经网络也许比图中描绘的量级还要大。

⁸指不是需要实际解决，但可以用来帮助更复杂问题寻找答案的问题




Figure 1.8: 数据集随着时间剧增。在二十世纪初期，统计学家使用成百上千次的手工编译研究数据集。在二十世纪五十年代到八十年代期间，受生物学启发的机器学习先驱经常使用的是小的、合成的数据集，比如信件的低分辨率位图，这些数据的使用是为了减少计算量的基础上使用神经网络实现特定功能。在二十世纪八十年代到九十年代，机器学习变得更加偏统计，并且开始使用万量级的数据集，比如 MNIST（如1.9）就是手写数字的扫描。在二十一世纪的前十年，出现了更多更复杂的数据集也是在这个量级，比如 CIFAR-10 就在持续的增加。在二十一世纪一零年代的前半部分，从十万到千万量级的更大的数据集完全的改变了深度学习能力的界限。这些数据集包括 Street View House Numbers，不同版本的 ImageNet，Sports-1M 等。在图的顶端我们可以看到翻译句子的数据集，比如由 Canadian Hansard 构造的 IBM 数据集，还有 WMT2014 英法翻译数据集等都远超了其他数据集的量级。




Figure 1.9: MNIST 数据集的示例。“NIST”意思是国家标准技术研究所，就是一开始收集这些数据的机构。“M”意思是“改变的”，因为这批数据为了使得机器学习算法更简单的应用进行了预处理。MNIST 数据集中有 0-9 的手写数字的扫描数据以及相应的标签。这个简单的分类是深度学习研究中最简单也最为广泛使用的测试。尽管这个任务对现代的技术来说很简单，但仍然很流行。Geoffrey Hinton 称其为“机器学习的果蝇”，意味着机器学习研究者可以在可控的实验条件下研究他们的算法，正如生物学家经常使用果蝇来帮助研究一样。

回想起来，如果用比水蛭还少的神经元数量解决不了复杂的人工智能问题是不足为奇的。即使是今天的网络，从计算系统的角度来看已经非常庞大了，但仍然比类如青蛙一般的原始脊椎动物所具有的神经元少。

模型的不不断增大的原因有 CPU 的计算能力不断增强，通用 GPU 的来临（12.0.1中会描述），网络连接的提速，适用于分布式计算的更优秀的软件架构。模型的增大是深度学习最重要的历史趋势之一，这个趋势被期待着在未来延续。

1.2.4 不断提高的精确度，复杂度以及对真实世界的冲击

从二十世纪八十年代以来，深度学习不断地提高自己的能力来进行精确的识别和预测。此外，深度学习也不断地成功的帮助更多的更广泛应用获得了成功。

最早的深度模型是用来识别被对齐后剪裁的非常小的图像，之后神经网络可以处理的图像量不断的增加。现在用于识别的网络可以处理非常多高清的图像，而且也不需要剪裁出需要识别的物体。最早的网络只能识别两类物体（或者是单类物体，其他是负样本），但现在的网络至少可以识别 1000 中不同的物体。最大的物体识别竞赛就是 ImageNet 每年都举办的大规模视觉识别挑战赛（ILSVRC）。深度学习迅速发展中的一个戏剧性的时刻就是卷积神经网络赢得了 Imagenet，并使得头 5 类错误率从 26.1% 降低到 15.3%，成为当时最先进的算法。这意味着卷积网络对每个输入图像产生了一个可能的类别清单，只有 15.3% 的样本的真实类别不在清单的前五名中。从此以后，ImageNet 比赛不断地被深度卷积网络拔得头筹，就在写本书期间，头五类错误率已经降低到了 3.6%，图1.12展示了这一情况。

深度学习对语音识别带来了巨大的影响。语音识别的效果在二十世纪九十年代有所提升，此后的识别效果一直停滞不前。深度学习的引入是的语音识别的错误率突降，有些错误率甚至降到了以前的一半。在12.1中我们会更为详尽的展开这段历史。

深度学习为行人识别以及图像分割带来了巨大的成功，并且在交通标志分类的任务上已经超越了人类的能力。

随着深度网络的规模变大、精度提升，它能处理也愈加复杂的问题。神经网络可以把图片直接转为文字描述，而非只找出其中某个物体。之前，大家认为这类的学习需要标注文字里提及的每个物体，而如 LSTM 之类的递归神经网络现在被用于建模序列和序列之间的关系。这类序列到序列的学习似乎是机器翻译的革命性的风口浪尖。

日益复杂的趋势由于神经元图灵机的引入被认为是合乎逻辑的，这种机器可以从记忆细胞中任意读写。这种神经网络可以从相应的样例中学习简单

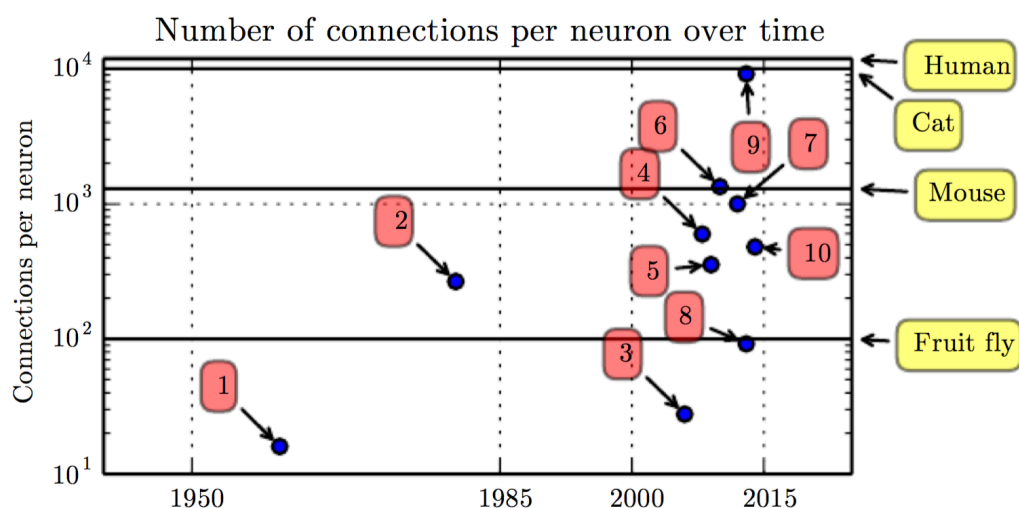


Figure 1.10: 最初人工神经网络的单个神经元的连接数的设定受限于硬件的能力，现在单个神经元连接数设定主要是出于网络设计的考量。有一些人工神经网络，单个神经元的连接数近似于一只猫，而具有如老鼠一般小型哺乳动物的单个神经元连接数的网络是非常普遍的。就算是人类的大脑，其单个神经元连接数也不是特别多。

1. 自适应线性元
2. 认知机
3. GPU 加速卷积网络
4. 深度玻尔兹曼机
5. 无监督卷积网络
6. GPU 加速多层感知机
7. 分布式自编码器
8. 多 GPU 卷积网络
9. COTS HPC 无监督卷积网络
10. GoogLeNet




Figure 1.11: 自从引入了隐藏元，人工神经网络的规模每 2.4 年会提升一倍

1. 感知机
2. 自适应线性元
3. 认知机
4. 早期的反向传播网络
5. 用于语音识别的递归神经网络
6. 用于语音识别的多层感知机
7. 平均场 sigmoid 信念网络
8. LeNet-5
9. Echo state 网络
10. 深度信念网络
11. GPU 加速卷积网络
12. 深度玻尔兹曼机
13. GPU 加速深度信念网络
14. 无监督卷积网络
15. GPU 加速多层感知机
16. OMP-1 网络
17. 分布式自编码器
18. 多 GPU 卷积网络
19. COTS HPC 无监督卷积网络
20. GoogLeNet

的功能，比如，它可以从扰乱的和有序的序列中学习对数字进行排序。这种自编程序的机器还在婴儿期，但原则上在未来很可能适用于几乎任何任务。

深度学习中另一项令人瞩目的成就是扩展了强化学习的领域。在强化学习中，一个自主代理必须从不断的尝试和失败中学习处理一个任务，而非是通过人工的指导。DeepMind 做了一款基于深度学习的强化学习系统可以学会玩 Atari 这种视频游戏，在许多任务上也达到了人类的水平。深度学习也显著的提升了机器人中强化学习的表现。

许多继续深度学习的应用利润都很客观。深度学习目前被许多顶级的科技公司使用，比如谷歌、微软、脸书、IBM、百度、苹果、网飞、英伟达和 NEC。

深度学习的进步也很大程度上依赖于软件架构的进步。比如 Theano、PyLearn2、Torch、DistBelief、Caffe、MXNet 和 TensorFlow 等软件库支撑了许多重要的研究项目和商业产品。

深度学习也其他的科学领域做出了贡献。现代的用于物体识别的卷积神经网络提供了神经学家可以研究的视觉处理模型。深度学习也为科技领域中处理海量的数据、做出有用的预测提供了工具。深度学习通过预测分子之间的交互来帮助制药企业设计新的药品、也曾被用来寻找亚原子和自动解析用于构建人脑三维图像的显微镜图像。我们期望深度学习未来能在更多的领域生根发芽。

总而言之，深度学习是一种机器学习的方法，机器学习在过去几十年大量的使用人类大脑的知识、统计学和应用数学等。近年来，主要因为更强大的计算机、更海量的数据集和训练更深的网络的技术出现，机器学习在普及性和实用性上都得到了极大的提升。深度学习的未来充满着挑战和机遇，而它也将去探索新的边界。




Figure 1.12: 自从深度学习达到了可以参与 ImageNet 竞赛的规模，就连续获得了多年的冠军，且每一年的错误率都有降低。

Part I

应用数学与机器学习基础

本部分介绍一些用于理解深度学习的基础数学概念。我们从定义函数和一些变量的应用数学开始，然后找到这些函数的最高点和最低点并量化置信度。

接着，我们会介绍机器学习的基本目标，并介绍如何使用特定的模型来模拟表示并完成这些目标。比如设计一个损失函数来描述模拟值和真值的差距，并使用训练算法来最小化损失函数。

这个基本的框架是许多机器学习算法的基础，包括一些不那么深的机器学习模型都有用到。在本书后续部分，我们会使用这个框架来建立深度学习算法。

2

线性代数

2.1 标量、向量、矩阵和张量

2.2 矩阵和向量乘法

2.3 单位矩阵和逆矩阵

2.4 线性相关和线性空间

2.5 秩

2.6 特殊的矩阵和向量

2.7 特征分解

2.8 奇异值分解

2.9 摩尔－彭若斯广义逆

2.10 求迹

2.11 行列式

2.12 示例：主成分分析

3

概率论和信息论

4

数值优化

5

机器学习基础

5.1 5.7.2

Part II

深度学习：实战

本部分将介绍可以用于解决实际问题的现代深度学习方法。

深度学习拥有着漫长历史和许多的应用，一些尝试至今已硕果累累。一些看起来野心十足的目标已经变为现实。深度学习中仍需探索的分支我们将留到最后一部分进行介绍。

本部分只介绍那些在工业中进行应用实践并获得成功的方法。

现代深度学习为有监督学习提供了一个十分强大的框架。通过增加层数或层间的单元数，网络可模拟更为复杂的函数。许多任务中都有把一个向量映射到另一个向量的工作，人类对这类工作翻译十分迅速，如果给出足够大的模型和大量的标签数据，深度学习也可以很好的完成这项工作。另外那些非向量映射可以描述的困难工作，甚至人类都需要时间思考和反应的，目前是不在深度学习讨论的范畴内。

本部分将讨论参数方程近似技术，这几乎要被所有的现代深度学习实践所使用。我们先介绍用于描述这些方程的前馈深度网络模型，然后我们会介绍正则化和优化等进一步的技术。缩放这些模型，使之适应于高分辨率的图像和长时间序列则需要进一步的讲述。我们将会介绍可用于缩放图像的卷积神经网络和处理时间序列的循环神经网络。最后，我们将总结一些可用于具体实践的指导，包括设计、构建、配置深度学习等，并对一些深度学习应用进行回顾。

本部分的章节对实践者来说最为重要，实践者们将开始使用深度学习技术解决真实世界中的问题。

6

深度前馈网络

深度前馈网络又被称为前馈神经网络或多层感知机，是一种深度学习模型。前馈神经网络的目标是近似一个函数 f^* 。比如对于一个分类器来说， $y = f^*(\mathbf{x})$ 把输入 \mathbf{x} 映射到类别 y 。前馈网络定义了这个映射 $\mathbf{y} = f(\mathbf{x}; \boldsymbol{\theta})$ ，并且通过学习参数 $\boldsymbol{\theta}$ 来近似真实的映射。

这类模型被称为前馈是因为信息通过输入 \mathbf{x} 流向用于定义函数 f 的中间计算，最后流向输出 \mathbf{y} 。网络中并没有从输出流入模型的反馈连接。当前馈网络扩展至包含反馈的连接时，就会被称为第10章中介绍的循环网络。

前馈网络对机器学习的实践者非常重要。它组成了许多重要商业应用的基础模块。比如，用于照片中物体识别的卷积网络就是一种特化的前馈网络。前馈网络也是通往循环网络的重要踏脚石，而循环网络支撑了许多自然语言相关的应用。

前馈神经网络之所以被称为网络是因为它非常典型的是由许多不同的函数组成的。这些函数的组成方式可以由一个有向无环图来描述。例如，函数 $f(\mathbf{x}) = f^{(3)}(f^{(2)}(f^{(1)}(\mathbf{x})))$ 可以由 $f^{(1)}$ 、 $f^{(2)}$ 、 $f^{(3)}$ 链式的串联组成，而链式结构是神经网络中最常用的结构。在这个情况中， $f^{(1)}$ 被称为网络的第一层， $f^{(2)}$ 被称为网络的第二层，以此类推。这个链的长度就定义了网络的深度。前馈网络的最后的一层被称为输出层。在神经网络的训练过程中，我们不断使得 $f(\mathbf{x})$ 近似于 $f^*(\mathbf{x})$ 。在不同的训练节点上，训练数据提供了关于 $f^*(\mathbf{x})$ 的带有噪声、近似的样本。每个样本 \mathbf{x} 都有一个使得 $y \approx f^*(\mathbf{x})$ 的标签。训练数据指定了在每个 \mathbf{x} 上输出层的直接表现，但没有直接指定其他层的行为。学习算法需要决定如何使用这些层来产生相应的输出，但训练数据并未指定每一层需要做什么。所以学习算法需要知道如何使用这些层来对 f^* 进行最优的近似，因为训练数据并不会为每一层都指定输出，这些没被指定输出的层就被称为隐层。

最终，这些网络被称为神经，因为它们是由神经科学启发而来的。网络

的每个隐层都是典型的向量值，隐层的维度决定了模型的宽度。这些向量中的每一个值都可以被看做对一个神经元的模拟。与其把这些层当做是向量间的映射函数，不如把每一层当做由许多并行的单元组成，而每个单元代表着一个向量到标量的映射函数。每个单元在这个场景下都被当做一个神经元，它从其他的单元中获取输入并计算自己的激活值。这种使用向量来代表网络层的想法来自于神经科学。 $f^{(i)}(\mathbf{x})$ 的计算行为也是或多或少来自于对生物神经元计算行为的观察。然而，现代的神经网络研究也受了许多数学和工程的指导，而且其目的也并非完美的模拟大脑。我们最好把前馈网络当初一种函数近似技术，用于达到统计上的概括，偶尔会借鉴一些我们对大脑的先验知识，而非用于对大脑进行建模。

对前馈网络进行了解的一种方法是先从线性模型开始，并考虑如何突破线性模型的限制。如逻辑回归和线性回归等线性模型非常吸引人，因为他们是封闭形式的或可以进行凸优化，可以有效和可靠的进行拟合。但线性模型也有个显著的缺点，它们只能拟合线性函数，因此线性模型不能理解两个输入变量之间的相互作用。

为了使得线性模型可以表达 \mathbf{x} 的非线性函数，我们可以把输入转换为 $\phi(\mathbf{x})$ ， ϕ 是一个非线性转换。等效的，我们也可以用5.1章中提到的核方法，通过应用 ϕ 的映射来获得非线性的学习算法。我们可以认为 ϕ 提供了一组可以描述 \mathbf{x} 的特征，或认为提供了 \mathbf{x} 的新的形式。

问题在于，我们如何选择映射 ϕ 。

1. 一个选择是使用通用的 ϕ ，比如 RBF 核用的无限维的 ϕ 。如果 $\phi(\mathbf{x})$ 的维度足够高，总会有办法来拟合训练集，但测试集上的泛化是个问题。通用化的特征映射通常只基于局部平滑的原则，并没有编码进足够的先验信息来进一步解决问题。
2. 另一个选择是手工的 ϕ 。在深度学习来临之前，这是一个主流方案。这个方法对每个不同任务都耗费数十年的人力，并需要实践者在不同的领域如语音识别或计算机视觉进行特化，且领域之间的共同点非常少。
3. 深度学习的策略则是学习 ϕ 。在这个方法中，模型是 $y = f(\mathbf{x}; \boldsymbol{\theta}, \mathbf{w}) = \phi(\mathbf{x}; \boldsymbol{\theta})^T \mathbf{w}$ 。参数 $\boldsymbol{\theta}$ 可以用于从许多的函数中学习想要的 ϕ ，参数 \mathbf{w} 用于控制 $\phi(\mathbf{x})$ 到指定的输出。这是一个深度前馈网络的示例， ϕ 是其隐层。这个方法是三个中唯一放弃了训练问题的凸性质的，但其优点远胜于缺点。在这个方法把输入转换后的形式记为 $\phi(\mathbf{x}; \boldsymbol{\theta})$ ，使用优化算法来找到使得转换后的性质最优的 $\boldsymbol{\theta}$ 。通过提供一个非常广阔的 $\phi(\mathbf{x}; \boldsymbol{\theta})$ 族，我们可以让这个办法像第一个方法一样具有高通用性。它也具有第二个选择的优点。人可以通过设计 $\phi(\mathbf{x}; \boldsymbol{\theta})$ 族来编码自身的知识，并帮助泛化。其优势是人类设计者只需要找到正确的函数簇而非找到唯一的正确的函数。

7

深度学习的正则化

8

训练深度模型的优化方法

9

卷积网络

9.1 9.10

10

序列模型：循环网络与递归网络

10.1 10.7

11

实战方法

12

应用

12.0.1 12.1.2

12.1 12.3

Part III

深度学习研究

13

线性模型

14

自编码器

15

表征学习

15.1 15.1

16

深度学习的结构化概率模型

17

蒙特卡洛方法

18

对抗分区函数

19

近似推理

20

深度生成式模型